

Hierarchical Reinforcement Learning: Maze with Tasks

Rubén Cid Costa¹, Aimar Nicuera Usandizaga², Daniel Obreo Sanz³

^{1, 2, 3}Universidad Carlos III de Madrid

¹100538592@alumnos.uc3m.es, ²100537352@alumnos.uc3m.es, ³100451058@alumnos.uc3m.es

Abstract

La realización de objetivos secuenciales en un entorno es una tarea compleja de modelar y aprender. Para poder representar estos escenarios, una de las técnicas más usadas es el Aprendizaje por Refuerzo Jerárquico (*Hierarchical Reinforcement Learning (HRL)*). En este contexto, este trabajo se enfoca en Feudal Learning, una variante de HRL que organiza las tareas en una estructura jerárquica de niveles de abstracción. Este documento detallará las bases teóricas y su aplicación sobre un ambiente de desarrollo con tareas de navegación y obtención de subobjetivos.

Introducción

En muchos dominios, como la robótica o sistemas autónomos, las tareas implican la realización de objetivos secuenciales en entornos complejos. La capacidad de modelar y aprender estos escenarios es un desafío crucial para la inteligencia artificial.

El aprendizaje por refuerzo jerárquico (HRL) se presenta como un enfoque para la resolución de estos problemas. Mientras que otras técnicas previas enfrentan dificultades para escalar con el número de tareas y su complejidad, el Aprendizaje por Refuerzo Jerárquico (HRL) organiza el proceso en niveles de abstracción. Dentro de este marco, el Aprendizaje Feudal se presenta como un enfoque que permite modelar las tareas mediante un jerarquía de abstracción.

Este trabajo se centra en el estudio de Feudal Learning, una variante de HRL. Se presentan las bases teóricas de esta técnica como diferentes algoritmos o métodos de aprendizaje que se han desarrollado en este campo. También, se mostrará su aplicación sobre un entorno simulado diseñado para tareas de navegación en laberintos y obtención de subobjetivos.

Marco Teórico y Estado del Arte

El aprendizaje por refuerzo jerárquico (HRL por sus siglas en inglés) se ha consolidado como una estrategia para abordar problemas complejos que involucran secuencias de tareas. Este enfoque se originó como una extensión de los modelos de decisión de Markov para tareas de largo horizonte

de decisión mediante el uso de modelos semi-MDP (Sutton, Precup, and Singh 1999). Con ellos, se establecen las bases teóricas para la abstracción temporal.

Posteriormente, con los años, han surgido una serie de algoritmos que implementa y abordan las limitaciones de HRL. Dietterich (Dietterich 2000) propuso el modelo MaxQ, descompone las tareas en jerarquías de subtareas para la optimización y planificación de diferentes funciones de valor. Por otro lado, en (Barto and Mahadevan 2003) se exploran los avances en estructuras jerárquicas para diferentes dominios y la relevancia de HRL para la resolución de problemas de gran complejidad.

Dentro de este marco teórico, el Aprendizaje Feudal se presenta como un técnica que organiza las tareas en niveles jerárquicos, donde cada nivel es operado con distintos grados de abstracción tanto en el estado como en temporalidad. Este enfoque (Dayan and Hinton 1992) divide la jerarquía en managers, que operan con abstracciones del estado y dan ordenes de acción y en workers que realizan las acciones. Esta colaboración jerárquica permite aprender y ejecutar tareas de manera más eficiente, aprovechando la modularidad y la capacidad de escalar a problemas complejos.

Sistemas de Control Feudal

En 1992, P. Dayan y G. Hinton (Dayan and Hinton 1992) definen los sistemas de control feudal como un reflejo de las sociedades feudales. En ellos, se define una jerarquía de *managers*, *supermanagers* y *workers*. Cada uno opera con un grado de abstracción de estados y temporal distinto. Los managers tienen poder absoluto sobre sus subordinados. Pueden dar ordenes que deben ser seguidas, dan tareas, recompensas y castigos si las ordenes no son seguidas. Esta estructura de jerarquía de mando permite aprender y comprender tareas complejas con el fin de maximizar el refuerzo.

Este sistema de control se basa en dos principios:

- **Ocultamiento de la Recompensa (Reward Hiding).** Los *managers* recompensan a los *submanagers* únicamente si operan en consonancia con las ordenes dadas. Los *submanagers* deben aprender a obedecer y aprender que debe hacer el siguiente agente para cumplir de manera eficiente. De la misma manera, el *submanager* es recompensado si su subordinado ejecuta las ordenes a pesar de no llegar a cumplir las ordenes propias del *submanager*.

En términos de implementación, los laberintos se han creado usando el algoritmo de Wilson. Las monedas se posicionan aleatoriamente en casillas libres del mapa. Para poder ser usados en CNN y RNN, por cada celda original se obtienen 4 celdas con las paredes. Esto genera un laberinto con dos veces el tamaño original como se ve en Fig. 2.

Para la experimentación, los agentes tienen como estado base (previo a transformaciones propias del método) la vista global del laberinto y la posición como coordenadas. Como acciones base, los agentes tienen las acciones de movimiento cardinales estándar NSWE (North-South-West-East). En algunos métodos, también se añade la acción * para los *managers*.

Experimentos

Para comprobar la efectividad de estos métodos, se ha realizado diferentes pruebas e implementaciones. El primer experimento se basa en una implementación que refleja fielmente los alineamientos de los sistemas de control feudales descritos. Basandose en el ejemplo de la publicación, se han planteado una jerarquía de cuatro niveles en la que cada manager tiene la mitad de resolución que el nivel anterior (Veasé Fig.3). Además, los manager tienen acceso al estado con la presencia de monedas en cada región.




Figure 3: Abstracciones y Niveles de Manager (cuadrado verde)

Resultados del Experimento

Debido a la disipación de las paredes que se experimentaba al realizar las abstracciones del mapa de estados a medida que se disminuía el nivel del gerente, el aprendizaje resultaba altamente perjudicado llegando transmitirse ordenes imposibles de realizar debida a la naturaleza cerrada del mapa del problema.

Para enfrentar dicha adversidad se probó a disminuir el número de gerentes/subgerentes, limitándose al uso del gerente de menor nivel de abstracción; aquel que veía el mapa de estados en la escala original. Por lo tanto, se realizó una disminución de agentes para quedarse con únicamente 2: un gerente encargado de determinar la siguiente zona destino y otro agente encargado en navegar hasta dicha posición de interés. Dicha estructura contaba con las mismas limitaciones y políticas de recompensa definidas para el proceso anterior.

Para facilitar el arranque y el uso del mánager desde el principio, se facilitaba al mánager una pista de la localización de las monedas que debían ser recogidas para que

guiara al trabajador (o worker) hacía dichas zonas sin necesidad de un proceso inicial donde las directrices del manager podían ser “ignoradas” debida a su aleatoriedad.

El trabajador a su vez realizaba un proceso de exploración que se veía recompensado cuando alcanzaba el punto objetivo determinado por el mánager. Mediante estas exploraciones, iba creando sus caminos o matrices Q que iba actualizando y afinando con el fin de encontrar el camino óptimo a partir de las recompensas obtenidas por llegar a los destinos asignados por el manager.

Pruebas Q Learning En cuanto al proceso de aprendizaje, se incluyeron diferentes implementaciones para ver la influencia que estas variaciones o perturbaciones tenían en el proceso de aprendizaje del super-agente. Las perturbaciones más comunes consistían en limitar el conocimiento que tenía el teacher (dándole solo el conocimiento de la solución empezando desde las coordenadas (1,1) o el conocimiento completo) o variando la posición de comienzo del agente.

En cuanto a los resultados se observieron sin ayudas externas el proceso de aprendizaje era más lento al tener que explorar muchos estados y no contar con una ayuda externa en caso de caer en bucles debido a los estrechos caminos que componían el mapa (5). Debido a este desconocimiento y falta de ayuda, las primeras iteraciones oscilaban en refuerzos negativos en su mayoría debido al proceso de exploración y explotación de conocimientos inciertos en dichas iteraciones.




Figure 4: Primeras 1000 iteraciones sin ayuda (16x16)

Sin embargo, la influencia de un teacher con conocimiento de un solo camino ante el que siempre tenía la solución óptima suponía una gran diferencia. Mediante esta ayuda, el worker era capaz de afinar mejor la ruta a seguir y por lo tanto se vió un incremento en la cantidad de refuerzo medio que se obtenían, pasando este a ser un valor positivo.

Aún así, al no contener información explotable desde todas las zonas del mapa de estados se observaban procesos de oscilaciones también en los momentos en los que se partía de zonas inexploradas. Esto se debía a que el agente tenía que lograr llegar hasta el punto más cercano de donde tenía opción de obtener conocimiento útil para poder obtener una ayuda, lo que lo ponía en similar situación que cuando no contaba con ayuda externa.




Figure 5: Primeras 1000 iteraciones con ayuda simple (16x16)

La máxima mejora del arranque inicial se logro mediante la introducción de rutas desde 3 zonas diferentes del mapa. Aunque dependiendo del azar estas rutas podrían aportar información redundante al tener inicios en lugares aleatorios del mapa, englobaban una mayor cantidad de estados, ofreciendo información explotable y útil en una subsección mayor del mapa. Debido a esto, la explotación del conocimiento y el reajuste ante un paso de exploración indeseado eran corregidos lo que llevaba a evitar bucles o episodios perdidos.¹




Figure 6: Primeras 1000 iteraciones con ayuda compleja (16x16)

En conclusión, esta nueva estructura feudal, de un noble (mánager) y un subordinado (worker), supuso una mejora en comparación con el nivel anterior debida a la simplicidad y mayor énfasis en las limitaciones del mapa de estados que permitía definir. Mediante los experimentos que se realizaron se observó no solo una mejora en el proceso de aprendizaje si no que una capacidad de llegar a soluciones en mapas de 20x20 tras 9000 iteraciones en caso de no incluir la ayuda del teacher o 1000 iteraciones cuando se le facilitaba el conocimiento explotable en 3 rutas.




Figure 7: Resultados tras 9000 iteraciones (20x20)

Pruebas FuN Otra técnica empleada de aprendizaje por refuerzo feudal son las FeUdal Networks (FuN), basadas en LSTMs. Se creó una adaptación de este tipo de red para que

¹ Situaciones en las que, debido a entrar en un callejón, se realizaban pasos hasta llegar al límite de los mismos por episodio.

podiera funcionar en el dominio tratado, y se establecieron y probaron distintos refuerzos que proporcionar a la red, evaluando su efectividad a la hora de encontrar soluciones.

La primera versión del modelo FuN, emplea una función de refuerzo muy similar a la usada durante el Q-learning, en donde se da un refuerzo positivo por alcanzar los objetivos y se dan refuerzos negativos a medida que transcurre el tiempo sin alcanzar un objetivo. Esta primera versión no produjo resultados demasiado positivos, el modelo a veces lograba completar el laberinto pero era común que se quedara atascado y que la pérdida no disminuyera. Todos los modelos probados en esta sección se han entrenado durante 500 épocas, con un límite de 2000 acciones por época (si en esas iteraciones no logra resolver el laberinto, se reinicia) y para comprobar si el modelo aprende correctamente se analizó si la pérdida disminuía a lo largo del tiempo. Se puede observar que no es el caso en la siguiente gráfica, donde el modelo aprende al principio y luego alcanza un punto estable.




Figure 8: Pérdida de la primera versión.

En la segunda versión, y para intentar mejorar la precisión del modelo, se añadió otra regla que penalizaba al modelo cuanto más lejos estuviera del objetivo definido por el mánager, para lo que se empleó la distancia de Manhattan. Esta nueva versión produjo resultados más inestables, donde no se llega a apreciar una auténtica mejora del modelo a lo largo del tiempo; los resultados se comparan con los de la versión anterior en la siguiente gráfica. Hay que tener en cuenta que la pérdida no está en la misma escala entre las dos versiones, y lo importante que se debe observar es una disminución de la misma a lo largo del tiempo, lo que indica que el modelo está aprendiendo, independientemente de la escala real de la pérdida. En la primera versión se penalizaba menos al modelo y por eso parece que tiene una pérdida menor, pero no quiere decir que sea mejor.




Figure 9: Pérdida de las dos primeras versiones.

Se comprueba que no mejora demasiado a lo largo del tiempo, y los valores son más inestables, lo que no es necesariamente algo negativo, pero tampoco parece estar ayudando mucho al modelo.

Como tercera versión de este método, se añadió una recompensa por explorar estados nuevos y un castigo por repetir estados, lo que resultó en un nuevo modelo que, si bien sí que parece que aprenda, sigue sin producir soluciones mejores que los otros métodos. Es posible que si se entrenara durante el tiempo suficiente, y modificando los parámetros de las recompensas hasta alcanzar los mejores valores se obtuvieran resultados similares e incluso mejores que los proporcionados por los otros métodos, pero requeriría una gran carga computacional.

Los resultados de esta versión, comparados con las otras dos, son los siguientes.




Figure 10: Pérdida de todas versiones.

Conclusiones

References

- Barto, A. G.; and Mahadevan, S. 2003. Recent advances in hierarchical reinforcement learning. *Discrete Event Dynamic Systems*, 13(1-2): 41–77.
- Dayan, P.; and Hinton, G. E. 1992. Feudal reinforcement learning. *Advances in neural information processing systems*, 5.

Dietterich, T. G. 2000. Hierarchical reinforcement learning with the MAXQ value function decomposition. *Journal of Artificial Intelligence Research*, 13: 227–303.

Science, T. D. 2024. Hierarchical Reinforcement Learning: Feudal Networks.

Sutton, R. S.; Precup, D.; and Singh, S. 1999. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1-2): 181–211.